UNIVERZITET U NIŠU

ELEKTRONSKI FAKULTET

Studijski program: Veštačka inteligencija i mašinsko učenje

Predmet: Prikupljanje i preobrada podataka za mašinsko učenje

SEMINSKI RAD I

KVALITET PODATAKA

Profesor: Aleksandar Stanimirović

Student: Teodora Božić

Broj indeksa: 2156

Niš, 2026.

Sadržaj

1. Uvod ... 3
2. Kvalitet podataka ... 4
   2.1 Pojam kvaliteta podataka ... 4
   2.2 Dimenzije kvaliteta podataka ... 4
3. Mere kvaliteta ... 8
   3.1 Statističke mere ... 8
   3.2 Raspodela podataka ... 9
   3.3 Varijansa ... 10
   3.4 Korelacija ... 11
4. Problemi kvaliteta podataka ... 12
   4.1 Nedostajući podaci ... 12
   4.2 Šum u podacima ... 12
   4.3 Ekstremne vrednosti (Outlieri) ... 13
   4.4 Neuravnoteženost podataka ... 13
   4.5 Duplirani i nekonzistentni zapisi ... 14
5. Uticaj kvaliteta podataka na modele mašinskog učenja ... 15
   5.1 Uticaj na tačnost i grešku modela ... 15
   5.2 Uticaj na generalizaciju i overfitting ... 15
   5.3 Uticaj na stabilnost i robusnost modela ... 15
   5.4 Uticaj na interpretabilnost modela ... 16
   5.5 Motivacija za praktični deo rada ... 16
6. Tehnike za unapređenje kvaliteta podataka u mašinskom učenju ... 16
   6.1 Obrada nedostajućih podataka ... 16
   6.2 Obrada ekstremnih vrednosti (outliera) ... 17
   6.3 Transformacije i skaliranje podataka ... 17
   6.4 Obrada neuravnoteženih skupova podataka ... 17
   6.5 Poređenje tehnika za unapređenje kvaliteta podataka ... 18
7. Preporuke i dobre prakse za obezbeđivanje kvaliteta podataka ... 18
   7.1 Obrada podataka u skladu sa kontekstom primene ... 18
   7.2 Balans između količine i kvaliteta podataka ... 18
   7.3 Standardizacija i dokumentovanje procesa obrade podataka ... 19
   7.4 Kontinuirana evaluacija kvaliteta podataka ... 19
   7.5 Sažetak preporuka ... 19
8. Zaključak ... 21
9. Literatura ... 22

1. Uvod

Razvoj savremenih informacionih sistema doveo je do toga da se u gotovo svim oblastima svakodnevno prikupljaju i obrađuju velike količine podataka. Podaci danas predstavljaju osnovu za donošenje odluka, analizu ponašanja i predviđanje budućih trendova, naročito u oblasti mašinskog učenja i analize podataka. Ipak, sama količina podataka nije dovoljna da bi se dobili pouzdani i relevantni rezultati, jer se kvalitet ulaznih podataka pokazuje kao jedan od ključnih faktora uspešne primene ovih metoda.

U realnim sistemima podaci se često prikupljaju iz različitih izvora i u neidealnim uslovima, što dovodi do pojave brojnih problema, kao što su netačne ili nepotpune vrednosti, nekonzistentni zapisi, neujednačena raspodela podataka i prisustvo ekstremnih vrednosti. Ovakvi problemi ne utiču samo na proces analize podataka, već se direktno odražavaju i na ponašanje modela mašinskog učenja, dovodeći do povećanja greške, slabe sposobnosti generalizacije i otežane interpretacije dobijenih rezultata. Zbog toga se obrada i procena kvaliteta podataka ne mogu posmatrati kao sporedni koraci, već kao sastavni deo svakog ozbiljnog procesa modelovanja.

Cilj ovog seminarskog rada jeste da se prikažu osnovni aspekti kvaliteta podataka i načini njihove analize u kontekstu mašinskog učenja. U teorijskom delu rada razmatraju se ključne dimenzije kvaliteta podataka, kao i statističke mere koje se koriste za procenu raspodele podataka, varijanse i korelacije između atributa. Praktični deo rada posvećen je ilustraciji uticaja kvaliteta podataka na performanse modela mašinskog učenja, kroz poređenje početnih (baseline) rezultata sa rezultatima dobijenim nakon primene tehnika za unapređenje kvaliteta podataka na izabranom skupu podataka.

2. Kvalitet podataka

2.1 Pojam kvaliteta podataka

Kvalitet podataka predstavlja stepen u kojem se podaci mogu pouzdano koristiti za analizu i donošenje zaključaka. Iako se često podrazumeva da su podaci koji postoje u nekom informacionom sistemu automatski upotrebljivi, praksa pokazuje da to vrlo često nije slučaj. Podaci mogu biti formalno prisutni, ali istovremeno netačni, nepotpuni ili međusobno neusaglašeni, što direktno utiče na rezultate svake dalje obrade.

U kontekstu analize podataka i mašinskog učenja, kvalitet podataka ima jednako, a često i veće značenje od izbora samog modela. Modeli mašinskog učenja uče obrasce isključivo na osnovu dostupnih podataka, pa se svi problemi prisutni u podacima direktno reflektuju na njihovo ponašanje. Loš kvalitet podataka može dovesti do pogrešnog učenja obrazaca, povećanja greške i donošenja zaključaka koji nemaju realno uporište u posmatranom problemu.

Važno je naglasiti da kvalitet podataka nije apsolutna kategorija, već u velikoj meri zavisi od konteksta u kojem se podaci koriste i ciljeva analize. Skup podataka koji je adekvatan za jednu vrstu analize može biti neadekvatan za drugu. Zbog toga se kvalitet podataka posmatra kroz različite dimenzije koje zajedno omogućavaju sveobuhvatniju procenu njihove upotrebljivosti.

2.2 Dimenzije kvaliteta podataka

Kvalitet podataka se najčešće opisuje kroz skup dimenzija koje omogućavaju sistematsku procenu različitih aspekata podataka. Ove dimenzije ne posmatraju se izolovano, već su međusobno povezane i zajedno utiču na krajnju pouzdanost analize i rezultate modela mašinskog učenja. U nastavku su opisane najznačajnije dimenzije kvaliteta podataka koje se najčešće razmatraju u praksi.

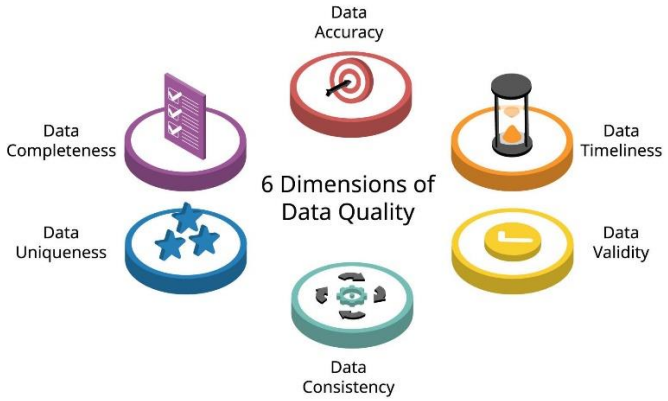

Слика 2-1 Osnovne dimenzije kvaliteta podataka u analizi podataka i mašinskom učenju.

2.2.1 Tačnost (Accuracy)

Tačnost podataka odnosi se na stepen u kojem vrednosti atributa odgovaraju stvarnim, ispravnim vrednostima. Netačni podaci mogu nastati usled grešaka u merenju, pogrešnog unosa ili korišćenja zastarelih informacija. Na primer, pogrešno evidentirana starost korisnika ili netačna cena proizvoda mogu značajno uticati na rezultate analize.

U mašinskom učenju, netačni podaci dovode do toga da model uči pogrešne obrasce, što se kasnije manifestuje kroz loše performanse i nepouzdane predikcije. Posebno su osetljivi modeli koji se oslanjaju na numeričke vrednosti, kod kojih i relativno mala odstupanja mogu imati značajan efekat na krajnje rezultate.

2.2.2 Potpunost (Completeness)

Potpunost podataka označava prisustvo svih potrebnih vrednosti u skupu podataka. Nedostajući podaci predstavljaju jedan od najčešćih problema u realnim skupovima podataka i mogu se javiti iz različitih razloga, kao što su tehnički problemi, neobavezna polja prilikom unosa ili prekidi u procesu prikupljanja podataka.

Nepotpuni podaci mogu otežati ili onemogućiti primenu određenih algoritama, jer mnogi modeli mašinskog učenja ne mogu direktno da rade sa nedostajućim vrednostima. Zbog toga se u praksi primenjuju različite tehnike za obradu nedostajućih podataka, pri čemu je važno imati u vidu da svaka od tih tehnika predstavlja određeni kompromis između očuvanja količine podataka i kvaliteta informacija koje oni nose.

2.2.3 Konzistentnost (Consistency)

Konzistentnost podataka podrazumeva odsustvo kontradiktornih ili međusobno neusaglašenih vrednosti unutar skupa podataka. Do problema konzistentnosti najčešće dolazi kada se podaci prikupljaju iz više različitih izvora ili kada ne postoje jasno definisana pravila validacije i kontrole unosa.

Primer nekonzistentnosti može biti situacija u kojoj isti entitet ima različite vrednosti istog atributa u različitim zapisima, ili kada zbir pojedinačnih vrednosti ne odgovara ukupnoj vrednosti. Ovakvi problemi mogu dovesti do pogrešne interpretacije podataka i dodatno otežati proces analize i modelovanja.

2.2.4 Jednoznačnost (Uniqueness)

Jednoznačnost se odnosi na odsustvo dupliranih zapisa u skupu podataka. Duplikati se često javljaju prilikom spajanja više izvora podataka ili kao posledica grešaka u sistemima za prikupljanje i skladištenje podataka.

Prisustvo dupliranih instanci može dovesti do pristrasnosti u modelima mašinskog učenja, jer se određeni obrasci pojavljuju češće nego što bi to bilo opravdano. Ovaj problem je posebno izražen kod manjih skupova podataka, gde i mali broj duplikata može značajno uticati na statističke mere i performanse modela.

2.2.5 Validnost (Validity)

Validnost podataka označava stepen u kojem vrednosti atributa poštuju unapred definisana pravila, formate i ograničenja. Na primer, vrednosti numeričkog atributa moraju pripadati dozvoljenom opsegu, dok kategoričke vrednosti treba da budu deo unapred definisanog skupa mogućih vrednosti.

Nevalidni podaci često ukazuju na probleme u procesu prikupljanja podataka ili na nedostatak adekvatne kontrole unosa. U analizi podataka, validnost predstavlja osnovni preduslov za dalje korake obrade i modelovanja, jer nevalidne vrednosti mogu narušiti pouzdanost celokupne analize.

2.2.6 Pravovremenost (Timeliness)

Pravovremenost se odnosi na ažurnost podataka i njihovu relevantnost u trenutku korišćenja. Podaci koji su u jednom trenutku bili tačni i korisni mogu vremenom postati zastareli, što ih čini manje pogodnim za analizu i donošenje odluka.

U dinamičnim sistemima, kao što su sistemi za preporuku ili e-commerce platforme, pravovremenost podataka ima poseban značaj, jer se obrasci ponašanja korisnika mogu brzo menjati. Korišćenje zastarelih podataka u takvim sistemima može dovesti do netačnih predikcija i narušavanja korisničkog iskustva.

3. Mere kvaliteta

Procena kvaliteta podataka ne može se zasnivati isključivo na subjektivnom utisku ili opštem opisu skupa podataka. Da bi se kvalitet podataka sistematski analizirao, koriste se različite statističke mere koje omogućavaju kvantitativan uvid u strukturu i osobine podataka. Ove mere pomažu u identifikaciji potencijalnih problema, kao što su velika rasipanja vrednosti, asimetrične raspodele ili snažne zavisnosti između atributa, koji mogu imati značajan uticaj na rezultate dalje analize i modelovanja.

U ovom poglavlju razmatraju se osnovne statističke mere koje se najčešće koriste u analizi kvaliteta podataka, sa posebnim fokusom na mere centralne tendencije, raspodelu podataka, varijansu i korelaciju između atributa.

3.1 Statističke mere

Statističke mere predstavljaju osnovni alat za opisivanje i razumevanje skupa podataka i često predstavljaju prvi korak u eksplorativnoj analizi podataka. Njihova primena omogućava sažet prikaz ključnih karakteristika podataka i pruža osnovu za identifikaciju potencijalnih problema u kvalitetu podataka.

Jedna od najčešće korišćenih mera centralne tendencije jeste **aritmetička sredina**, koja daje informaciju o prosečnoj vrednosti posmatranog atributa i definiše se kao:

$$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

gde je *xi* vrednost i-tog podatka, a n ukupan broj instanci u skupu podataka.

Aritmetička sredina predstavlja prosečnu vrednost posmatranog atributa i često se koristi kao osnovna referentna tačka u analizi podataka. Međutim, važno je naglasiti da je ova mera osetljiva na prisustvo ekstremnih vrednosti, koje mogu značajno pomeriti njenu vrednost. Zbog toga aritmetička sredina ne mora uvek verno da odražava tipičnu vrednost u skupu podataka, naročito kada raspodela nije simetrična.

Pored sredine, često se koristi i **medijana**, koja predstavlja srednju vrednost u sortiranom nizu podataka. Medijana je znatno otpornija na prisustvo ekstremnih vrednosti i često se smatra pouzdanijom merom centralne tendencije u skupovima podataka sa asimetričnom raspodelom. Značajna razlika između sredine i medijane može ukazivati na potencijalne probleme u kvalitetu podataka, kao što su prisustvo outliera ili izražena asimetrija raspodele.

Za analizu rasipanja vrednosti koriste se **mere disperzije**, među kojima su najznačajnije varijansa i standardna devijacija. Ove mere opisuju u kojoj meri se pojedinačne vrednosti razlikuju od prosečne vrednosti. Velike vrednosti varijanse mogu ukazivati na heterogenost podataka ili prisustvo šuma, dok male vrednosti sugerišu da su podaci međusobno slični i stabilni.

Važno je naglasiti da statističke mere same po sebi ne određuju direktno da li su podaci dobrog ili lošeg kvaliteta, ali predstavljaju osnovu za dalje analize i omogućavaju identifikaciju problema koji zahtevaju dodatnu pažnju.

3.2 Raspodela podataka

Raspodela podataka predstavlja način na koji su vrednosti određenog atributa raspoređene unutar skupa podataka. Analiza raspodele podataka ima ključnu ulogu u proceni kvaliteta podataka, jer mnoge metode mašinskog učenja implicitno ili eksplicitno pretpostavljaju određene karakteristike raspodele ulaznih podataka.

Jedan od najčešće razmatranih oblika raspodele jeste **normalna raspodela**, koja je simetrična i definisana srednjom vrednošću i standardnom devijacijom. Međutim, u realnim skupovima podataka često dolazi do odstupanja od normalne raspodele, pri čemu se javljaju različiti oblici asimetrije.

Asimetrija raspodele, poznata kao *skewness*, ukazuje na to da li su vrednosti u skupu podataka više koncentrisane ka levoj ili desnoj strani distribucije. Pozitivna asimetrija označava situaciju u kojoj se veći broj vrednosti nalazi sa leve strane, dok ekstremne vrednosti „vuku“ raspodelu udesno, dok negativna asimetrija ima suprotno značenje. Izražena asimetrija može negativno uticati na performanse određenih modela i često zahteva primenu transformacija podataka.

Na primer, raspodele koje sadrže mali broj veoma velikih vrednosti često pokazuju pozitivnu asimetriju, što može uticati na stabilnost statističkih mera i performanse određenih modela.

Pored asimetrije, važna karakteristika raspodele je i **kurtosis**, koja opisuje stepen „šiljatosti“ ili „ravnosti“ raspodele u poređenju sa normalnom raspodelom. Visoke vrednosti kurtosis-a mogu ukazivati na prisustvo velikog broja ekstremnih vrednosti, što predstavlja potencijalni problem kvaliteta podataka.

Vizuelna analiza raspodele podataka, kroz histogram, box-plot ili slične grafičke prikaze, često pruža intuitivniji i jasniji uvid u strukturu podataka nego same numeričke mere, zbog čega predstavlja neizostavan deo eksplorativne analize.

Na slici 3.1 prikazani su tipični oblici raspodele podataka koji se često sreću u realnim skupovima podataka, uključujući normalnu raspodelu, asimetrične raspodele i raspodelu sa izraženim ekstremnim vrednostima.

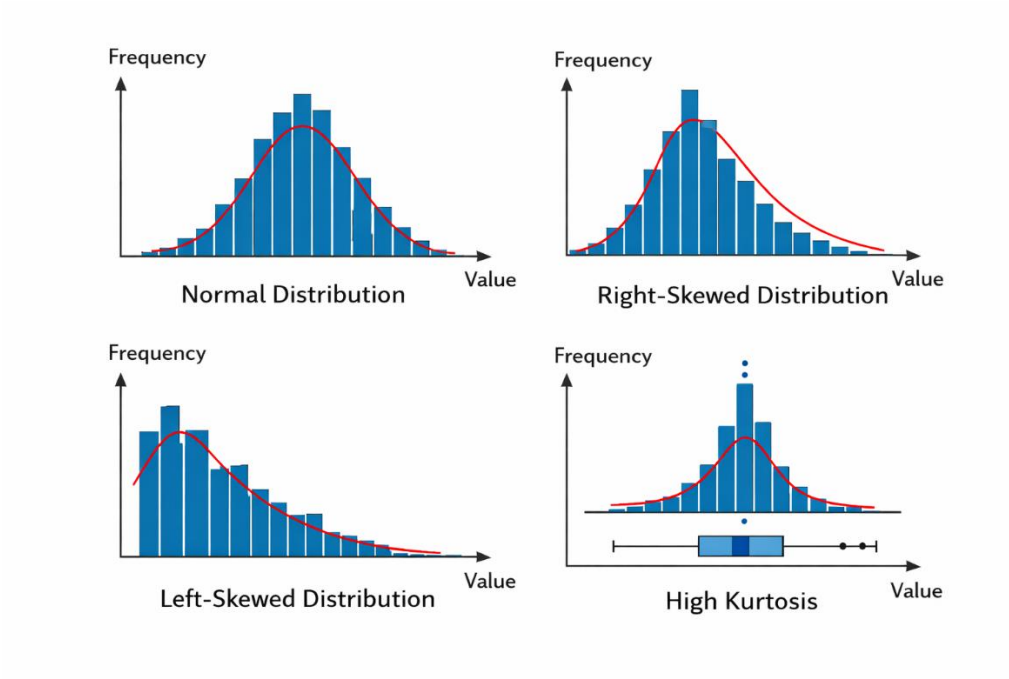

Слика 3-1 Ilustracija osnovnih oblika raspodele podataka koji se javljaju u praksi, uključujući normalnu raspodelu, asimetrične raspodele i raspodelu sa izraženim ekstremnim vrednostima.

3.3 Varijansa

Varijansa predstavlja jednu od osnovnih mera disperzije i opisuje prosečno kvadratno odstupanje vrednosti od njihove sredine. Ona daje informaciju o rasipanju podataka i stepenu njihove heterogenosti, a definiše se kao:

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2$$

Iz same formule za varijansu može se uočiti da se razmatraju kvadratna odstupanja pojedinačnih vrednosti od aritmetičke sredine. Kvadriranjem odstupanja obezbeđuje se da pozitivna i negativna odstupanja ne poništavaju jedno drugo, čime se dobija pouzdana mera rasipanja podataka. Veća vrednost varijanse ukazuje na veće razlike među vrednostima atributa, dok manja varijansa sugeriše da su vrednosti međusobno slične.

U kontekstu kvaliteta podataka, varijansa ima važnu ulogu u identifikaciji atributa koji sadrže malo informacija, ali i atributa koji pokazuju izrazitu nestabilnost.

Atributi sa veoma malom varijansom često imaju ograničenu diskriminativnu moć, jer njihove vrednosti ne variraju značajno među instancama. Takvi atributi često imaju mali doprinos modelu i ponekad se uklanjaju u fazi pripreme podataka. Sa druge strane, izrazito velika varijansa može ukazivati na prisustvo šuma ili ekstremnih vrednosti, što može negativno uticati na stabilnost modela.

Analiza varijanse omogućava donošenje informisanih odluka o daljoj obradi podataka, uključujući primenu tehnika normalizacije, standardizacije ili uklanjanje određenih atributa.

3.4 Korelacija

Korelacija predstavlja meru međusobne zavisnosti između dva numerička atributa. U analizi kvaliteta podataka, korelacija se koristi za identifikaciju linearnih ili monotoničnih veza između atributa, kao i za otkrivanje potencijalne redundanse u skupu podataka.

Najčešće korišćena mera korelacije jeste **Pearsonov koeficijent korelacije**, koji meri jačinu i smer linearne veze između dva atributa i definiše se kao:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

Vrednosti ovog koeficijenta kreću se u opsegu od -1 do 1, gde vrednosti bliske -1 ili 1 ukazuju na snažnu korelaciju, dok vrednosti bliske nuli ukazuju na slabu ili nepostojeću linearnu zavisnost.

U slučajevima kada veza između atributa nije linearna, često se koristi **Spearmanov koeficijent korelacije**, koji se zasniva na rangiranju vrednosti i otporniji je na prisustvo ekstremnih vrednosti.

Visok stepen korelacije između atributa može dovesti do problema **multikolinearnosti**, što otežava interpretaciju modela i može negativno uticati na njegove performanse. Zbog toga je analiza korelacije važan korak u proceni kvaliteta podataka i izboru relevantnih atributa za modelovanje.

4. Problemi kvaliteta podataka

U realnim skupovima podataka problemi kvaliteta predstavljaju pravilo, a ne izuzetak. Bez obzira na oblast primene, podaci se često prikupljaju u neidealnim uslovima, iz različitih izvora i uz ograničene mehanizme kontrole validnosti. Zbog toga se u fazi analize podataka gotovo uvek susreću različiti oblici degradacije kvaliteta, koji mogu značajno da utiču na rezultate modelovanja i donošenje zaključaka.

Problemi kvaliteta podataka ne utiču samo na pouzdanost statističkih mera, već se direktno odražavaju i na ponašanje modela mašinskog učenja, njihovu stabilnost i sposobnost generalizacije. U nastavku su opisani najčešći problemi kvaliteta podataka koji se javljaju u praksi i koji imaju direktan uticaj na performanse modela mašinskog učenja.

4.1 Nedostajući podaci

Nedostajući podaci predstavljaju jedan od najčešćih problema u analizi podataka. Do njihovog pojavljivanja može doći usled grešaka u prikupljanju podataka, prekida u radu sistema, neuspelih merenja ili neobaveznih polja prilikom unosa podataka. Prisustvo nedostajućih vrednosti može značajno otežati dalju analizu, jer mnogi algoritmi mašinskog učenja ne mogu direktno da rade sa takvim podacima.

Uticaj nedostajućih podataka zavisi od njihovog obima i obrasca pojavljivanja. Mali procenat nedostajućih vrednosti često se može zanemariti ili relativno jednostavno obraditi, dok veći procenat može dovesti do značajnog gubitka informacija i pristrasnosti rezultata. Poseban problem nastaje kada nedostajući podaci nisu nasumično raspoređeni, već su povezani sa određenim karakteristikama podataka, što može dovesti do sistematskih grešaka u analizi i pogrešnih zaključaka.

4.2 Šum u podacima

Šum u podacima odnosi se na slučajne ili nepredvidive varijacije u vrednostima atributa koje ne nose korisnu informaciju. Šum može nastati kao posledica grešaka u merenju, ograničene preciznosti senzora, komunikacionih problema ili spoljašnjih uticaja tokom prikupljanja podataka.

Prisustvo šuma otežava učenje relevantnih obrazaca, jer model pokušava da prilagodi i nasumične fluktuacije u podacima. Ovakva situacija često dovodi do prekomernog prilagođavanja (overfitting), gde model postiže dobre rezultate na trening skupu, ali slabo generalizuje na nove podatke. Zbog toga je identifikacija i ublažavanje šuma važan korak u procesu pripreme podataka, posebno kod modela osetljivih na varijacije u ulaznim vrednostima.

4.3 Ekstremne vrednosti (Outlieri)

Outlieri predstavljaju vrednosti koje značajno odstupaju od većine podataka u skupu. Oni mogu nastati usled grešaka u merenju ili pogrešnog unosa podataka, ali i kao rezultat retkih, ali legitimnih događaja. Razlikovanje ova dva slučaja često predstavlja izazov u analizi podataka i zahteva pažljivo razmatranje konteksta u kojem se podaci koriste.

Ekstremne vrednosti mogu imati snažan uticaj na statističke mere, kao što su aritmetička sredina i varijansa, i time značajno promeniti ponašanje modela. Posebno su osetljivi linearni modeli i modeli zasnovani na udaljenostima, kod kojih outlieri mogu u velikoj meri uticati na parametre modela. Zbog toga je identifikacija outliera važan deo procene kvaliteta podataka, ali njihovo uklanjanje mora biti pažljivo razmotreno kako ne bi došlo do gubitka relevantnih informacija.

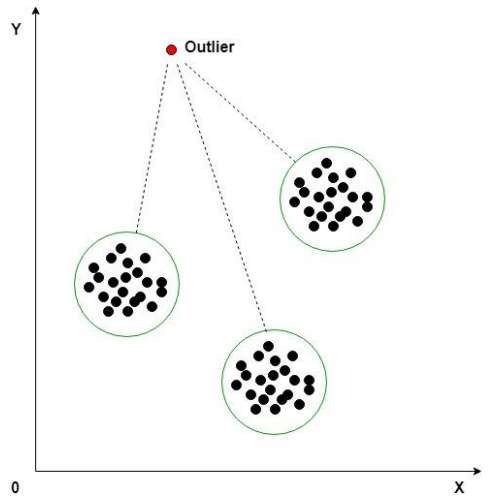

Слика 4-1 Ilustracija ekstremnih vrednosti u skupu podataka

4.4 Neuravnoteženost podataka

Neuravnoteženost podataka predstavlja problem koji se najčešće javlja u klasifikacionim zadacima, kada su neke klase znatno zastupljenije od drugih. U takvim slučajevima, model može postići visoku ukupnu tačnost, ali istovremeno veoma loše performanse za manje zastupljene klase.

Ovaj problem kvaliteta podataka može dovesti do pogrešnog zaključka o uspešnosti modela, jer standardne metrike, poput tačnosti, ne odražavaju stvarne performanse u svim delovima prostora podataka. Neuravnoteženost zahteva posebnu pažnju u fazi evaluacije modela i često zahteva primenu specifičnih tehnika za obradu podataka ili prilagođavanje modela.

4.5 Duplirani i nekonzistentni zapisi

Duplirani zapisi i nekonzistentne vrednosti često nastaju prilikom integracije podataka iz više izvora ili usled nedostatka jedinstvenih identifikatora. Duplikati mogu dovesti do prekomernog uticaja određenih instanci na model, dok nekonzistentni zapisi otežavaju interpretaciju podataka i smanjuju njihovu pouzdanost.

Prisustvo ovakvih problema može narušiti statističke mere i dovesti do pristrasnih rezultata, što se direktno odražava na performanse modela mašinskog učenja. Zbog toga je detekcija i obrada duplikata i nekonzistentnosti neophodan korak u procesu obezbeđivanja kvaliteta podataka, posebno u sistemima koji koriste podatke iz više heterogenih izvora.

5. Uticaj kvaliteta podataka na modele mašinskog učenja

Kvalitet podataka ima direktan i često presudan uticaj na ponašanje i performanse modela mašinskog učenja. Iako se u praksi često veliki značaj pridaje izboru algoritma i podešavanju hiperparametara, loš kvalitet ulaznih podataka može značajno ograničiti potencijal čak i najnaprednijih modela. Modeli mašinskog učenja uče obrasce isključivo na osnovu dostupnih podataka, zbog čega se svi problemi prisutni u podacima neminovno reflektuju i na rezultate procesa učenja.

Uticaj kvaliteta podataka ne ogleda se samo u smanjenju tačnosti modela, već i u njegovoj stabilnosti, sposobnosti generalizacije i mogućnosti interpretacije rezultata. U nastavku su razmotreni najvažniji aspekti kroz koje kvalitet podataka utiče na modele mašinskog učenja.

5.1 Uticaj na tačnost i grešku modela

Jedan od najočiglednijih efekata lošeg kvaliteta podataka jeste povećanje greške modela. Netačni, šumoviti ili nekonzistentni podaci dovode do toga da model uči pogrešne ili nepotpune obrasce, što se direktno odražava na smanjenu tačnost predikcija. U takvim uslovima, model ne uspeva da uspostavi pouzdanu vezu između ulaznih atributa i ciljne promenljive.

Prisustvo ekstremnih vrednosti i šuma dodatno pogoršava ovu situaciju, jer model pokušava da prilagodi i nasumične ili atipične vrednosti. Ovaj efekat je posebno izražen kod regresionih modela i modela zasnovanih na udaljenostima, koji su osetljivi na raspodelu podataka i prisustvo outliera.

5.2 Uticaj na generalizaciju i overfitting

Generalizacija predstavlja sposobnost modela da postigne dobre performanse na podacima koji nisu korišćeni tokom faze treninga. Loš kvalitet podataka može ozbiljno narušiti ovu sposobnost. Kada su podaci opterećeni šumom ili sadrže veliki broj irelevantnih ili pogrešnih vrednosti, model može naučiti obrasce koji nisu reprezentativni za stvarni problem.

Ovakva situacija često dovodi do pojave prekomernog prilagođavanja (overfitting), gde model postiže dobre rezultate na trening skupu, ali slabo performira na test podacima. Iako se overfitting često povezuje sa kompleksnošću modela, kvalitet podataka ima jednako važnu ulogu u njegovom nastanku. Čak i relativno jednostavni modeli mogu pokazati lošu generalizaciju ukoliko su trenirani na podacima lošeg kvaliteta.

5.3 Uticaj na stabilnost i robusnost modela

Stabilnost modela odnosi se na njegovu osetljivost na promene u ulaznim podacima. Modeli trenirani na podacima lošeg kvaliteta često pokazuju veliku varijabilnost rezultata čak i pri

malim promenama u skupu podataka. Ovakva nestabilnost otežava pouzdanu primenu modela u realnim sistemima.

Prisustvo šuma, outliera i nekonzistentnih zapisa može značajno smanjiti robusnost modela, naročito u situacijama kada se model primenjuje na nove podatke koji se razlikuju od trening skupa. Unapređenje kvaliteta podataka, kroz postupke čišćenja i transformacije, često dovodi do stabilnijih i pouzdanijih modela, sposobnih da se adekvatno ponašaju u realnim uslovima.

5.4 Uticaj na interpretabilnost modela

Pored performansi, kvalitet podataka ima značajan uticaj i na interpretabilnost modela, odnosno mogućnost razumevanja i objašnjenja dobijenih rezultata. Kada su podaci opterećeni greškama, šumom ili redundantnim atributima, interpretacija modela postaje otežana, jer nije jasno da li naučeni obrasci odražavaju stvarne veze u podacima ili su posledica problema u kvalitetu ulaznih podataka.

Ovaj aspekt je posebno važan u oblastima u kojima je objašnjivost modela od velikog značaja, kao što su medicina, finansije i sistemi za podršku donošenju odluka. U takvim slučajevima, unapređenje kvaliteta podataka predstavlja osnovni preduslov za pouzdanu i smisleniju interpretaciju rezultata mašinskog učenja.

5.5 Motivacija za praktični deo rada

Analiza uticaja kvaliteta podataka na modele mašinskog učenja jasno ukazuje na to da obrada i unapređenje kvaliteta podataka nisu opcioni koraci, već neophodan deo svakog ozbiljnog procesa modelovanja. Zbog toga je u praktičnom delu ovog rada poseban akcenat stavljen na poređenje rezultata modela pre i nakon unapređenja kvaliteta podataka.

Kroz praktični primer biće demonstrirano kako promene u kvalitetu podataka, kao što su obrada ekstremnih vrednosti, transformacija raspodele i uklanjanje problematičnih atributa, mogu dovesti do poboljšanja performansi, stabilnosti i pouzdanosti modela mašinskog učenja.

6. Tehnike za unapređenje kvaliteta podataka u mašinskom učenju

Problemi kvaliteta podataka, kao što su nedostajući podaci, prisustvo šuma, ekstremne vrednosti i neuravnoteženost klasa, prethodno razmotreni u okviru analize problema kvaliteta podataka, mogu značajno narušiti performanse modela mašinskog učenja i pouzdanost dobijenih rezultata.

Zbog toga unapređenje kvaliteta podataka predstavlja jedan od ključnih koraka u procesu pripreme podataka, koji prethodi samom modelovanju.

6.1 Obrada nedostajućih podataka

Problem nedostajućih podataka, prethodno razmotren u Poglavlju 4 kao jedan od najčešćih izazova u analizi podataka, može se ublažiti primenom različitih tehnika obrade.

Najjednostavniji pristup predstavlja uklanjanje instanci sa nedostajućim vrednostima, što je opravdano samo u situacijama kada je procenat takvih podataka mali i kada njihovo uklanjanje ne dovodi do značajnog gubitka informacija.

U praksi se češće primenjuje imputacija nedostajućih vrednosti, gde se one zamenjuju procenjenim vrednostima. Jednostavne metode imputacije, poput zamene sredinom ili medijanom, omogućavaju očuvanje svih instanci, ali mogu smanjiti varijansu i uvesti pristrasnost. Naprednije tehnike, zasnovane na korišćenju drugih atributa, daju realističnije procene, ali povećavaju složenost obrade. Izbor metode zavisi od obrasca pojavljivanja nedostajućih vrednosti i značaja atributa u modelu.

6.2 Obrada ekstremnih vrednosti (outliera)

Ekstremne vrednosti, koje su u prethodnom poglavlju identifikovane kao značajan problem kvaliteta podataka, zahtevaju pažljivo razmatranje prilikom izbora tehnike obrade.

Njihova identifikacija se najčešće zasniva na statističkim metodama, poput interkvartilnog raspona ili Z-score kriterijuma, koje omogućavaju jednostavno uočavanje odstupanja od tipičnih vrednosti.

Nakon identifikacije, outlieri se mogu ukloniti, transformisati ili zadržati u skupu podataka. Uklanjanje ekstremnih vrednosti može poboljšati stabilnost modela, ali nosi rizik gubitka relevantnih informacija. Zbog toga se u praksi često primenjuju robusni pristupi koji umanjuju njihov uticaj, a da se pritom očuva informativnost podataka.

6.3 Transformacije i skaliranje podataka

Transformacije i skaliranje podataka koriste se za prilagođavanje razmera i raspodele atributa zahtevima algoritama mašinskog učenja. Normalizacija i standardizacija su najčešće metode skaliranja i posebno su važne kod algoritama zasnovanih na udaljenostima.

Pored skaliranja, transformacije raspodele, poput logaritamske transformacije, primenjuju se radi smanjenja asimetrije i ublažavanja uticaja ekstremnih vrednosti. Iako ove tehnike mogu značajno unaprediti performanse modela, njihova primena zahteva pažljivo razmatranje interpretabilnosti transformisanih podataka.

6.4 Obrada neuravnoteženih skupova podataka

Neuravnoteženost podataka predstavlja problem u klasifikacionim zadacima, jer modeli često favorizuju dominantnu klasu. Jedan od načina rešavanja ovog problema jeste

poduzorkovanje dominantne klase, čime se smanjuje pristrasnost, ali i količina dostupnih podataka.

Alternativno, naduzorkovanje manjinske klase omogućava očuvanje svih instanci, ali može dovesti do prekomernog prilagođavanja modela. Zbog toga izbor tehnike zavisi od veličine skupa podataka, značaja manjinske klase i zahteva konkretne primene.

6.5 Poređenje tehnika za unapređenje kvaliteta podataka

Različite tehnike za unapređenje kvaliteta podataka imaju različite prednosti i ograničenja, zbog čega je njihov izbor uslovljen kontekstom problema. Uporedni prikaz tehnika omogućava sistematičan pregled dostupnih rešenja i olakšava donošenje informisanih odluka u procesu pripreme podataka.

7. Preporuke i dobre prakse za obezbeđivanje kvaliteta podataka

Na osnovu razmatranja problema kvaliteta podataka, kao i tehnika za njihovo unapređenje predstavljenih u prethodnim poglavljima, može se zaključiti da kvalitet podataka ima presudan uticaj na uspešnost analize podataka i performanse modela mašinskog učenja.

Jedan od najvažnijih koraka u radu sa podacima jeste rana analiza kvaliteta podataka, pre same izgradnje modela. Eksplorativna analiza podataka omogućava uvid u raspodelu vrednosti, prisustvo nedostajućih podataka, ekstremnih vrednosti i potencijalnih nekonzistentnosti. Pravovremena identifikacija ovih problema omogućava donošenje informisanih odluka o daljoj obradi podataka i sprečava kasnije komplikacije u procesu modelovanja.

7.1 Obrada podataka u skladu sa kontekstom primene

Kvalitet podataka ne treba posmatrati kao apsolutnu kategoriju, već u kontekstu konkretne primene i ciljeva analize. Tehnike koje su pogodne u jednom slučaju mogu biti neadekvatne u drugom. Na primer, uklanjanje ekstremnih vrednosti može poboljšati performanse određenih modela, ali istovremeno dovesti do gubitka važnih informacija ukoliko te vrednosti predstavljaju legitimne, ali retke pojave.

Zbog toga je preporučljivo da se svaka odluka o obradi podataka donosi uz razumevanje značenja podataka i njihove uloge u konkretnom problemu. U praksi je često korisno kombinovati statističke kriterijume sa domenim znanjem kako bi se izbegle pogrešne interpretacije i neželjene posledice obrade podataka.

7.2 Balans između količine i kvaliteta podataka

Jedan od čestih izazova u obradi podataka jeste pronalaženje ravnoteže između očuvanja količine podataka i unapređenja njihovog kvaliteta. Agresivno uklanjanje instanci sa nedostajućim

vrednostima ili ekstremnih vrednosti može dovesti do značajnog smanjenja skupa podataka, što može negativno uticati na proces učenja modela.

Sa druge strane, zadržavanje problematičnih podataka može povećati šum i smanjiti pouzdanost rezultata. Zbog toga se preporučuje primena postepenog i pažljivo kontrolisanog pristupa obradi podataka, uz kontinuiranu evaluaciju uticaja svake intervencije na performanse modela.

7.3 Standardizacija i dokumentovanje procesa obrade podataka

Kako bi se obezbedila ponovljivost i pouzdanost rezultata, važno je da proces obrade podataka bude jasno definisan i dokumentovan. Standardizacija koraka obrade, kao što su čišćenje podataka, transformacije i izbor atributa, omogućava lakšu reprodukciju eksperimenata i smanjuje rizik od grešaka.

U kontekstu mašinskog učenja, dokumentovanje procesa obrade podataka olakšava interpretaciju rezultata i omogućava doslednu primenu istih tehnika na nove podatke. Ovo je posebno važno u sistemima koji se kontinuirano razvijaju i u kojima se modeli periodično ponovo treniraju.

7.4 Kontinuirana evaluacija kvaliteta podataka

Kvalitet podataka ne predstavlja statičku osobinu, već se vremenom može menjati. Promene u načinu prikupljanja podataka, ponašanju korisnika ili spoljašnjim uslovima mogu dovesti do degradacije kvaliteta podataka, čak i u sistemima koji su inicijalno bili dobro postavljeni.

Zbog toga je preporučljivo da se evaluacija kvaliteta podataka sprovodi kontinuirano, a ne samo u inicijalnoj fazi analize. Praćenje osnovnih statističkih mera, raspodele podataka i performansi modela može poslužiti kao indikator potencijalnih problema i omogućiti pravovremenu reakciju.

7.5 Sažetak preporuka

Na osnovu razmatranja iznetih u ovom poglavlju mogu se izdvojiti sledeće ključne preporuke:

- sprovesti detaljnu eksplorativnu analizu podataka pre faze modelovanja,
- donositi odluke o obradi podataka u skladu sa kontekstom problema i ciljevima analize,
- pažljivo balansirati između količine i kvaliteta podataka,
- dokumentovati sve korake obrade podataka radi ponovljivosti i interpretabilnosti,
- kontinuirano pratiti kvalitet podataka tokom vremena.

Primena ovih preporuka doprinosi pouzdanijoj analizi podataka i stabilnijim modelima mašinskog učenja, čime se povećava ukupna vrednost i primenljivost dobijenih rezultata.

8. Zaključak

Kroz ovaj seminarski rad razmatran je značaj kvaliteta podataka u kontekstu analize podataka i mašinskog učenja. Pokazano je da kvalitet podataka predstavlja jedan od ključnih faktora koji utiču na uspešnost modelovanja, često podjednako važan, a neretko i važniji od samog izbora algoritma ili podešavanja hiperparametara.

U teorijskom delu rada analiziran je pojam kvaliteta podataka, njegove osnovne dimenzije, kao i najčešće statističke mere koje se koriste za procenu kvaliteta, uključujući raspodelu podataka, varijansu i korelaciju između atributa. Takođe su razmotreni najčešći problemi kvaliteta podataka, kao što su nedostajući podaci, šum, ekstremne vrednosti, neuravnoteženost i nekonzistentni zapisi, kao i njihov uticaj na performanse, stabilnost i interpretabilnost modela mašinskog učenja.

Na osnovu izloženog može se zaključiti da obrada i unapređenje kvaliteta podataka predstavljaju neophodne korake u svakom ozbiljnom procesu modelovanja, a ne sporednu ili opcionalnu fazu. Primenom odgovarajućih tehnika za analizu i poboljšanje kvaliteta podataka moguće je značajno unaprediti pouzdanost i robusnost modela, kao i smanjiti rizik od pogrešnih zaključaka.

U praktičnom delu rada biće demonstrirano kako unapređenje kvaliteta podataka utiče na rezultate modela mašinskog učenja kroz poređenje početnih (baseline) rezultata i rezultata dobijenih nakon primene odabranih tehnika obrade podataka. Time se teorijska razmatranja potvrđuju na konkretnom primeru i dodatno naglašava značaj kvaliteta podataka u realnim primenama mašinskog učenja.

9. Literatura

1. Jiawei Han, Micheline Kamber, Jian Pei,
   Data Mining: Concepts and Techniques, Third Edition,
   Morgan Kaufmann, 2012.
2. Salvador García, Julián Luengo, Francisco Herrera,
   Data Preprocessing in Data Mining,
   Springer, 2015.
3. Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar,
   Introduction to Data Mining, Second Edition,
   Addison-Wesley, 2019.
4. Ihab F. Ilyas, Xu Chu,
   Data Cleaning,
   ACM Books, 2019.
5. Jason W. Osborne,
   Best Practices in Data Cleaning: A Complete Guide to Everything You Need to Do Before and After Collecting Your Data,
   SAGE Publications, Inc., 2012.
6. Jason Brownlee,
   Data Preparation for Machine Learning: Data Cleaning, Feature Selection and Data Transforms in Python,
   Machine Learning Mastery, 2020.
7. Michael Walker,
   Python Data Cleaning Cookbook: Detect and Remove Dirty Data and Extract Key Insights with Pandas, NumPy, and SciPy,
   Packt Publishing, 2022.